

Visão Geral da Solução

Para o desenvolvimento da solução foi escolhida uma arquitetura on-premises, utilizando Python, Visual Studio Code, SQL Server Express e Power BI Desktop.

A opção por uma solução totalmente local foi uma decisão técnica e de segurança. Durante a análise dos requisitos, não foi possível garantir que os dados disponibilizados para o desafio fossem públicos ou autorizados para processamento em serviços de terceiros. Dessa forma, optou-se por evitar qualquer dependência de plataformas web ou serviços em nuvem, garantindo que todas as etapas do processamento ocorressem exclusivamente no ambiente local.

Caso houvesse uma infraestrutura previamente disponibilizada, como uma solução baseada em Docker, N8N, banco de dados hospedado em ambiente privado e protegido por firewall, a arquitetura poderia ser diferente utilizando orquestração por workflows e integrações entre serviços. Entretanto, considerando o tempo disponível para o desenvolvimento e buscando minimizar dependências externas, foi desenvolvida uma aplicação desktop em Python responsável por executar toda a pipeline de dados.

Processo de ETL

O processamento foi desenvolvido utilizando a biblioteca Pandas para leitura, tratamento e transformação dos arquivos Excel e Parquet. Clientes e Regiões receberam validações adicionais diretamente no Pandas para eliminar duplicidades e aumentar a consistência dos dados. Os arquivos de maior volume foram carregados para a camada Bronze utilizando comandos SQL executados pelo Python, reduzindo o consumo de memória e melhorando a performance.

Arquitetura do Data Warehouse

O banco foi estruturado em três camadas: Bronze (stg), Silver (ods) e Gold (dw).

Bronze (stg)


Responsável pelo recebimento dos dados exatamente como disponibilizados pela origem. Não existem regras de negócio nesta etapa. A procedure `etl.sp_TruncateStage` executa apenas `TRUNCATE` nas tabelas da camada Bronze.

Silver (ods)

Responsável pelo tratamento e padronização das informações. A procedure `etl.sp_LoadODS` limpa as tabelas Silver e recarrega os dados tratados, iniciando a aplicação das regras de negócio.

Gold (dw)

Camada destinada exclusivamente ao consumo do Power BI. Foi adotado o modelo dimensional Star Schema. As procedures `etl.sp_LoadDimClient`, `etl.sp_LoadDimDate`, `etl.sp_LoadDimRegion` e `etl.sp_LoadFactDeliveryPerformance` realizam os tratamentos finais e a carga das dimensões e da tabela fato.




Estratégia de Atualização

Foi adotada uma estratégia de Full Load. A cada execução da pipeline: As tabelas Bronze são limpas. Os arquivos são carregados novamente. A camada ODS é reconstruída. A camada Gold é recriada para consumo do Power BI. Essa abordagem garante consistência entre todas as camadas e evita divergências decorrentes de cargas incrementais.


Fluxo da Solução

FLUXO DA SOLUÇÃO

Arquitetura On-Premise – Python – SQL Server – Power BI



DESCRIÇÃO DAS CAMADAS



Estratégia de Atualização: Full Load – A cada execução da pipeline, todas as camadas são limpas e recarregadas, garantindo consistência total dos dados no DW e no BI.